

ROBUST DE-ANONYMIZATION OF LARGE DATASETS


Phương pháp khử ẩn danh hiệu quả đối với các tập dữ liệu quy mô lớn



1. GIỚI THIỆU & ĐỘNG LỰC NGHIÊN CỨU



ĐỘNG LỰC NGHIÊN CỨU




Micro-data là **dữ liệu chi tiết về từng cá nhân**, ngày càng được công khai để phục vụ nghiên cứu và phân tích dữ liệu.

- Tuy nhiên, nhiều dataset vẫn **chứa thông tin nhạy cảm** hoặc **riêng tư cần được bảo vệ**.



Vấn đề: Thực hành phổ biến là **xóa các trường định danh trực tiếp** trước khi công bố, với kỳ vọng rằng **dữ liệu sau đó là "ẩn danh"**
=> Điều này là **sai lầm nghiêm trọng**.



Các cuộc tấn công tiêu biểu đã biết



Sweeney (1997)



Kết hợp **hồ sơ xuất viện Massachusetts** (đã xóa tên) với **danh sách cử tri công khai** → re-identify bệnh nhân cụ thể.



AOL Search Data (2006)



DNA Sequences

Các cuộc tấn công tiêu biểu đã biết



Sweeney (1997)



AOL Search Data (2006)



Dữ liệu **tìm kiếm "ẩn danh"** của 650,000 người dùng bị **khai thác để nhận diện cá nhân**.



DNA Sequences

Các cuộc tấn công tiêu biểu đã biết



Sweeney (1997)



AOL Search Data (2006)




DNA Sequences




Chuỗi ADN ẩn danh bị re-identify qua **cross-correlation** với dữ liệu y tế khác.

ĐÓNG GÓP CỦA BÀI BẢO



Mô hình hình thức

Xây dựng mô hình toán học nghiêm ngặt cho **privacy breach** trong micro-data ẩn danh, không giả định trước **quasi-identifier** cố định như **k-anonymity**.



Thuật toán tổng quát

Đề xuất thuật toán **de-anonymization** hoạt động dưới các giả định rất nhẹ về phân phối dữ liệu, **robust** với nhiễu và **sanitization**, chỉ cần **5–10** thuộc tính **auxiliary**.



Case study Netflix

Áp dụng lên **Netflix Prize Dataset** (500,000 hồ sơ), chứng minh rằng kẻ tấn công chỉ cần **biết một ít về subscriber** là có thể **nhận diện toàn bộ lịch sử xem phim**.

2. KHÁI NIỆM CƠ BẢN



CẤU TRÚC DATABASE


Database **D** được mô hình hóa là **ma trận $N \times M$** , trong đó:

- **Mỗi hàng** là một **hồ sơ cá nhân (record)**.
- **Mỗi cột** là một **thuộc tính (attribute)**.

Với **dataset phim**:

- N = số **subscriber**.
- M = **tổng số phim trong catalog**.
- Mỗi ô có thể là **rating** (1–5 sao), **ngày xem**, hoặc $\perp$ (null — không có dữ liệu).

Support của một record r - ký hiệu **$\text{supp}(r)$** , là tập hợp các **thuộc tính non-null** (tức là các phim mà subscriber đó thực sự đã đánh giá).




TÍNH THƯA (SPARITY)

- **Hiểu cơ bản:** Đây là **đặc tính then chốt** của micro-data thực tế. Mỗi hồ sơ chỉ có **giá trị cho một phần nhỏ** trong hàng chục nghìn thuộc tính.
- Dữ liệu rating tuân theo **phân phối power law/heavy tail**: Chỉ một số ít phim phổ biến có nhiều rating, trong khi đa số phim là phim hiếm với rất ít rating.



=> Mỗi người dùng có **mẫu rating gần như riêng biệt**, làm dữ liệu trở nên cực kỳ sparse và khiến k-anonymity khó tạo được các nhóm người dùng tương đồng.



TÍNH THƯA (SPARITY)

Định nghĩa hình thức: Database D là (ϵ, δ) -sparse w.r.t. similarity measure Sim nếu

$$\Pr_r [\text{Sim}(r, r') > \epsilon \ \forall r' \neq r] \leq \delta$$

Nghĩa là: Với **xác suất $\geq 1-\delta$** , không có record nào trong database gần record r hơn ngưỡng ϵ .
Bài báo chứng minh empirically rằng Netflix Prize Dataset là **overwhelmingly sparse** — đại đa số subscriber không có một subscriber nào khác đủ tương đồng trong toàn bộ 500,000 hồ sơ.



ĐỘ ĐO TƯƠNG ĐỒNG (SIMILARITY MEASURE)

Hàm Sim: Ánh xạ một cặp thuộc tính hoặc bản ghi vào khoảng $[0, 1]$.



Công thức tổng quát:

(Dạng tổng quát hóa của cosine similarity)

$$Sim(r_1, r_2) = \frac{\sum Sim(r_{1i}, r_{2i})}{|supp(r_1) \cup supp(r_2)|}$$

Áp dụng trong Case Study Netflix:

- **Sim = 1:** Nếu rating và ngày xem nằm trong ngưỡng cho phép.
- **Sim = 0:** Nếu ngược lại.



TẠI SAO K-ANONYMITY THẤT BẠI?

Cơ chế của k-anonymity

YÊU CẦU

Publisher phải **xác định trước** tập các **thuộc tính định danh giả** (quasi-identifiers) mà kẻ tấn công (adversary) có thể biết.



MỤC TIÊU

Đảm bảo mỗi **tổ hợp quasi-identifier** xuất hiện **ít nhất k lần** trong tập dữ liệu để cá nhân được "hòa lẫn" vào nhóm.



TẠI SAO K-ANONYMITY THẤT BẠI?

NGUYÊN NHÂN THẤT BẠI ĐỐI VỚI DỮ LIỆU ĐA CHIỀU

*Không thể dự đoán tri
thức của kẻ tấn công*



Trong thực tế, publisher **không thể biết trước** chính xác kẻ tấn công sẽ **nắm giữ những thuộc tính nào** của từng cá nhân để thiết lập quasi-identifier phù hợp.

Sự bùng nổ tổ hợp




Số lượng các tổ hợp thuộc tính tăng theo hàm mũ so với số chiều dữ liệu. Việc làm **mở dữ liệu để đạt được mức k tương đồng** trên tất cả các chiều là **bất khả thi** về mặt thực tế.

Tính thừa cực cao



Do tính chất thừa, **mỗi bản ghi** gần như là **duy nhất**. Ngay cả khi đã loại bỏ các thông tin trực tiếp, các đặc điểm hành vi riêng biệt vẫn đủ để định danh cá nhân một cách chính xác.



3. MÔ HÌNH HÌNH THỨC



MÔ HÌNH ADVERSARY (KẺ TẤN CÔNG)

Mục tiêu: Giải mã định danh (De-anonymize) một bản ghi r được chọn ngẫu nhiên từ cơ sở dữ liệu D .



CÔNG CỤ:

(Kẻ tấn công được cung cấp thông tin hỗ trợ)

$$aux = Aux(r) \in X^M$$

Áp dụng trong Case Study Netflix:

- **Sim = 1:** Nếu rating và ngày xem nằm trong ngưỡng cho phép.
- **Sim = 0:** Nếu ngược lại.



BA ĐỊNH NGHĨA PRIVACY BREACH

Định nghĩa 2 — (θ, ω) -Deanonymization

| Tồn tại thuật toán A nhận D và $Aux(r)$, xuất r' sao cho: $\Pr[\text{Sim}(r, r') \geq \theta] \geq \omega$

Kẻ tấn công bắt đầu với aux gần r trên một tập nhỏ thuộc tính, rồi tìm r' gần r trên toàn bộ tập thuộc tính. Đây là dạng **khuếch đại kiến thức**:

Ít thông tin $\rightarrow$ học được toàn bộ hồ sơ



BA ĐỊNH NGHĨA PRIVACY BREACH

Định nghĩa 3 — De-anonymization từ Sample $D^{\wedge} \subset D$

| Vì Netflix chỉ phát hành **1/8 database**, cần xử lý trường hợp **record của target chưa chắc có** trong $D^{\wedge}$:

- Nếu $r \in D^{\wedge}$: Xuất r' với $\Pr[\text{Sim}(r, r') \geq \theta] \geq \omega$
- Nếu $r \notin D^{\wedge}$: Xuất $\perp$ với **xác suất** $\geq \omega$

Ngưỡng lỗi $(1-\omega)$ được dùng thống nhất cho cả **false positive** lẫn **false negative** — gọi là **"equal error rate"**



BA ĐỊNH NGHĨA PRIVACY BREACH

Định nghĩa 4 — Entropic Deanonimization

| Là phương pháp sử dụng **Entropy Shannon** để đo lường **độ bất định** còn lại trong tập ứng viên định danh

Mục tiêu: Định lượng chính xác **kẻ tấn công** cần thêm bao nhiêu "**lượng thông tin**" để xác định mục tiêu.



CÔNG THỨC

$$E\left[\min_{\{r' \in D', \text{Sim}(r, r') \geq \theta\}} H_S(\Pi, r')\right] \leq H$$

Trong đó:

- **D'**: Tập các ứng viên tiềm năng.
- **P_i**: Phân phối xác suất trên tập ứng viên.
- **Sim(r, r')**: Độ tương đồng giữa hồ sơ mục tiêu và hồ sơ ứng viên.
- **H_S**: Entropy Shannon tối thiểu.

4. THUẬT TOÁN DE-ANONYMIZATION



TEMPLATE TỔNG QUÁT

Thuật toán có 3 thành phần chính

1

SCORING

Tính $\text{Score}(\text{aux}, r')$ cho mỗi record $r' \in D^{\wedge}$, đo mức độ tương đồng giữa r' và auxiliary information của adversary.

2


MATCHING

Áp dụng matching criterion lên tập điểm số $\rightarrow$ xác định "matching set". Nếu matching set rỗng $\rightarrow$ xuất $\perp$ (target không có trong sample).

3

SELECTION

Xuất record có điểm cao nhất (theo Định nghĩa 2/3) hoặc xuất phân phối xác suất trên matching set (theo Định nghĩa 4).



ALGORITHM 1A – ĐƠN GIẢN, PHÂN TÍCH ĐƯỢC



Hàm chấm điểm

$$\text{Score}(aux, r') = \min_{i \in \text{supp}(aux)} \text{Sim}(aux_i, r'_i)$$

(Điểm số được xác định bởi **thuộc tính có độ tương đồng thấp nhất** (bottleneck))



Tập Matching

$$D' = \{ r' \in \hat{D} : \text{Score}(aux, r') > \alpha \}$$

ALGORITHM 1B – THỰC TIỄN, TỐI ƯU

A. Weighted Scoring.



Weighted Scoring (Điểm số được tính theo **tổng trọng số** của các thuộc tính)

$$\text{Score}(aux, r') = \sum_{i \in \text{supp}(aux)} wt(i) \cdot \text{Sim}(aux_i, r'_i)$$

Trong đó trọng số: $wt(i) = \frac{1}{\log |\text{supp}(i)|}$

- **|supp(i)|** là số subscriber đã rating phim i
- Phim càng hiếm → trọng số càng cao → giá trị nhận diện càng mạnh

ALGORITHM 1B – THỰC TIỄN, TỐI ƯU

B. Matching Criterion (Eccentricity).



Tính **max**, **max2**, **σ** của tập điểm số

Điều kiện matching

$$\frac{\text{max} - \text{max}_2}{\sigma} < \varphi$$

- Nếu điều kiện đúng → không có match đủ nổi bật
- Ngược lại → chọn record có điểm cao nhất

Tham số $\varphi = 1.5$ (eccentricity) đảm bảo record được chọn phải "vượt trội" rõ ràng so với ứng viên thứ hai, **hạn chế false positive**.

ALGORITHM 1B – THỰC TIỄN, TỐI ƯU

C. Selection (*Exponential Distribution*)

$$\Pi(r') = c \cdot e^{\text{Score}(aux, r') / \sigma}$$

- Xác suất chọn tăng theo điểm số
- Record điểm cao được ưu tiên mạnh hơn
- Hiệu quả hơn phân phối đều của Algorithm 1A

ALGORITHM 1B – THỰC TIỄN, TỐI ƯU

D. Netflix Case Study

$$\text{Score}(aux, r') = \sum_{i \in \text{supp}(aux)} wt(i) \cdot \left(e^{(\rho_i - \rho'_i)/1.5} + e^{(d_i - d'_i)/30} \right)$$

Trong đó:

- ρ_i : Rating trong aux
- ρ'_i : Rating trong candidate record
- d_i và d'_i : Ngày xem tương ứng

- ρ_o : 1.5
- d_o : 30 ngày

5. PHÂN TÍCH LÝ THUYẾT



TRƯỜNG HỢP TỔNG QUÁT – ĐỊNH LÝ 1

Định lý: Cho $\epsilon, \delta \in (0,1)$. Nếu thông tin bổ trợ (aux) bao gồm ít nhất m thuộc tính được chọn ngẫu nhiên từ bản ghi r :

$$m \geq \frac{\log N - \log \epsilon}{-\log(1 - \delta)}$$

(Với điều kiện độ tương đồng $\text{Sim}(\text{aux}_i, r_i) \geq 1-\epsilon$, thì **tập dữ liệu D** có thể bị **giải định danh** với độ chính xác xác định)

NHẬN XÉT QUAN TRỌNG

- m **phụ thuộc logarithm** vào N nên khi database tăng 1000 lần, số thuộc tính cần biết tăng không đáng kể.
- **Phụ thuộc tuyến tính** vào $1/\delta \rightarrow$ nếu cho phép accuracy thấp hơn một chút, cần ít background knowledge hơn nhiều.
- False positive rate tổng $\leq N \cdot (1-\delta)^m$, giảm về 0 khi m đủ lớn.

DATASET THƯA – ĐỊNH LÝ 2

Định lý: Nếu D là $(1-\epsilon-\delta, \epsilon)$ -sparse, thì D có thể được $(1, 1-\epsilon)$ -deanonymize.

| Với sparse database, matching set chứa đúng 1 record: chính là **record đúng của target**.
Xác suất **false positive gần bằng 0**. Đây chính là trường hợp của Netflix Dataset.

HỆ QUẢ THỰC TẾ

Sparsity không chỉ là đặc tính kỹ thuật — nó là lý do vì sao de-anonymization **chính xác hơn trên dữ liệu thực tế** so với dự đoán worst-case.



K-DEANONYMIZATION – ĐỊNH LÝ 3

Định lý: Với D là $(1-\varepsilon-\delta, \varepsilon)$ -sparse và $m = \log(N/(k-1)) / \log(1/(1-\delta))$

- | D có thể được **$(1, 1/k)$ -deanonymize** $\rightarrow$ **record** đúng nằm trong **top-k ứng viên** với xác suất $\geq 1/k$.
- | D có thể được **$(1, \log k)$ -deanonymize entropically** $\rightarrow$ **adversary** chỉ cần thêm **$\log k$ bits** để hoàn tất.

Ý NGHĨA

Ngay cả khi **adversary** chỉ "**k-deanonymize**" (xuất k ứng viên thay vì 1), điều này cũng **đủ nguy hiểm nếu k nhỏ** và k nhỏ vì m cần thiết giảm theo logarithm.

DE-ANONYMIZATION TỪ SAMPLE – ĐỊNH LÝ 4 & 5

- | **Định lý 4:** Thuật toán hoạt động đúng ngay cả khi **chỉ có $\hat{D} \subset D$** : nếu $r \in \hat{D}$ thì de-anonymize thành công; nếu $r \notin \hat{D}$ thì xuất $\perp$ đúng — cả hai với xác suất $\geq 1-\epsilon$.
- | **Định lý 5:** Nếu D không phải (ϵ, δ) -sparse, thì **random $1/\lambda$ -subset $\hat{D}$ không phải $(\epsilon, \delta\gamma/\lambda)$ -sparse** với **xác suất $\geq 1-\gamma$** .

Ý NGHĨA THỰC TIỄN

Sparsity của sample ngụ ý **sparsity của toàn bộ database gốc** (với xác suất cao). **Không thể "ẩn" sparsity bằng cách chỉ publish sample** — và nếu cố tình phá vỡ sparsity của sample, dataset sẽ **mất utility cho collaborative filtering** (điều mà Netflix không muốn).

6. CASE STUDY: NETFLIX PRIZE DATASET



⋮⋮⋮ BỐI CẢNH


Tháng 10/2006, Netflix công bố dataset gồm **100,480,507 ratings** của **480,189 subscribers** (từ 12/1999 đến 12/2005) để hỗ trợ cuộc thi Netflix Prize. Đây là khoảng **1/8 tổng số subscriber Netflix** cuối năm 2005.

TUYÊN BỐ CỦA NETFLIX

Không có thông tin định danh khách hàng nào trong dataset. Ngay cả khi bạn biết toàn bộ ratings của mình, bạn cũng khó nhận ra chúng vì chỉ có sample nhỏ và dữ liệu đã bị perturbation.



Thực tế (theo phân tích của bài báo): Tuyên bố này sai ở mọi điểm.





MỨC ĐỘ PERTURBATION THỰC TẾ

Bài báo kiểm chứng bằng cách lấy **lịch sử rating từ Netflix website của một số người quen** (biết tên thật) rồi tìm **trong dataset**

Kết quả: Một subscriber có **1/306 ratings** bị thay đổi, subscriber khác có **5/229 ratings** bị thay đổi. Mức nhiễu **quá nhỏ** để ảnh hưởng đến thuật toán robust. Dataset cũng không hề được k-anonymize ($k > 1$).

Lý do Netflix không thể perturbation nhiều: Dataset được publish để cải thiện **recommendation algorithm**. **Nhiều lớn sẽ phá vỡ cross-attribute correlations** → dataset mất giá trị cho mục đích nghiên cứu, đi ngược lại mục tiêu của Netflix Prize.



THIẾT LẬP THỰC NGHIỆM



SIMILARITY FUNCTION

- Ngưỡng **threshold Sim = 1** nếu rating trong khoảng ± 0 hoặc ± 1 sao, ngày xem trong khoảng ± 3 hoặc ± 14 ngày (hoặc ∞ nếu không có ngày).
- Cũng cho **phép một phần auxiliary information hoàn toàn sai**: "aux gồm m phim trong m_0 " nghĩa là m_0 phim được cung cấp nhưng chỉ m phim thực sự đúng.



ECCENTRICITY

$\varphi = 1.5$ — matching được xác nhận khi điểm cao nhất vượt điểm thứ 2 ít nhất 1.5 lần độ lệch chuẩn.

KẾT QUẢ DE-ANONYMIZATION



VỚI EXACT RATINGS VÀ APPROXIMATE DATES:

Số lượng phim	Độ lệch thời gian ($\pm$)	Tỷ lệ nhận diện hồ sơ
2 phim	14 ngày	~43% (nhận diện duy nhất)
2 phim	3 ngày	~68%
3 trong 4 phim	14 ngày	~70%
6 trong 8 phim	14 ngày	99%

KẾT QUẢ DE-ANONYMIZATION

KHÔNG CÓ NGÀY XEM (CHỈ RATINGS):

- 6/8 PHIM NGOÀI TOP-500 MOST-RATED: 84% HỒ SƠ ĐƯỢC NHẬN DIỆN — NGAY CẢ KHI HOÀN TOÀN KHÔNG BIẾT THỜI ĐIỂM XEM.

Về entropic de-anonymization:

A priori entropy: ~ 19 bits (không biết gì về target)

Với 2 phim: entropy giảm còn $\sim 4-5$ bits cần thêm

Với 6/8 phim: entropy giảm xuống dưới 1 bit — gần như xác định hoàn toàn

Phát hiện record không trong sample: Thuật toán đồng thời phát hiện chính xác khi record của target không nằm trong 1/8 được publish, với accuracy tương đương (Figure 2 trong paper).

7. HÀM Ý & KẾT LUẬN



HÀM Ý PHÁP LÝ & CHÍNH SÁCH

Netflix vi phạm privacy policy của chính mình

Policy của Netflix phân chia thông tin thành "personal" và "non-personal", khẳng định ratings là non-personal và có thể dùng ẩn danh. Bài báo chứng minh sự phân chia này là false dichotomy — ratings khi kết hợp với nhau và với background knowledge trở thành thông tin định danh.



"Forward Privacy" bị phá vỡ

Một khi dữ liệu đã bị link với danh tính thật, mọi bí danh tương lai của người đó đều có thể bị phá vỡ. Ví dụ: Alice bị de-anonymize từ Netflix. Kể từ đó, bất kỳ virtual identity "Ecila" nào Alice tạo ra đều không thể tiết lộ thông tin về phim đã xem mà không bị truy vết về Alice thật.

Hàm ý cho data protection law

Cần định nghĩa lại "anonymized data" dựa trên rủi ro re-identification thực tế, không chỉ dựa trên việc đã xóa các trường tên/địa chỉ.

HÀM Ý KỸ THUẬT

Removing PII không đủ

Bản chất của micro-data high-dimensional là mỗi hồ sơ gần như unique trong không gian thuộc tính, ngay cả khi không có tên hay địa chỉ.

1

Removing PII không đủ

2

k -anonymity thất bại hoàn toàn trên high-dimensional data

3

Perturbation nhỏ không có tác dụng

4

Differential Privacy là hướng đúng

HÀM Ý KỸ THUẬT

k-anonymity thất bại hoàn toàn trên high-dimensional data

Được chứng minh cả lý thuyết (Aggarwal 2005) lẫn thực nghiệm. Không thể áp dụng k-anonymity cho dataset loại Netflix.

1

Removing PII không đủ

2

k-anonymity thất bại hoàn toàn trên high-dimensional data

3

Perturbation nhỏ không có tác dụng

4

Differential Privacy là hướng đúng

HÀM Ý KỸ THUẬT

Perturbation nhỏ không có tác dụng

Thuật toán được thiết kế explicit để robust với nhiễu. Chỉ khi mức perturbation đủ lớn để phá vỡ utility của dataset thì mới có tác dụng bảo vệ — nhưng lúc đó dataset không còn dùng được cho mục đích ban đầu.

1

Removing PII không đủ

2

k-anonymity thất bại hoàn toàn trên high-dimensional data

3

Perturbation nhỏ không có tác dụng

4

Differential Privacy là hướng đúng

HÀM Ý KỸ THUẬT

Differential Privacy là hướng đúng

Bài báo không đề xuất giải pháp cụ thể nhưng ngụ ý rằng cần cơ chế mạnh hơn k-anonymity, có bảo đảm toán học về privacy ngay cả khi adversary có background knowledge tùy ý — đây là định hướng của Differential Privacy (Dwork 2006).

1

Removing PII không đủ

2

k-anonymity thất bại hoàn toàn trên high-dimensional data

3


Perturbation nhỏ không có tác dụng

4

Differential Privacy là hướng đúng

TẦM QUAN TRỌNG CỦA PRIVACY NETFLIX

Câu hỏi không phải là "người dùng trung bình có coi trọng lịch sử xem phim không?" mà là **"có user nào bị tổn hại bởi việc công bố không?"**, và câu trả lời rõ ràng là có. Thông tin về **xu hướng chính trị, tôn giáo, tình dục** có thể là nhạy cảm ngay cả khi người dùng không chủ động che giấu thông tin đó trên các platform khác.



KẾT LUẬN

Bài báo chứng minh rằng **micro-data high-dimensional không thể được bảo vệ bằng cách xóa tên**, đây là giới hạn cơ bản của privacy trong công bố dữ liệu công khai. Thuật toán de-anonymization hoạt động dưới:

- Giả định rất nhẹ về phân phối dữ liệu
- Chỉ cần 2–8 thuộc tính auxiliary
- Robust với nhiễu lên tới 2/8 attributes sai và sai ngày ≤ 14 ngày
- Có thể detect khi target không có trong sample

Hướng nghiên cứu tiếp theo được tác giả đề xuất: khai thác mạng xã hội và cluster structure từ anonymous records để tăng cường de-anonymization thêm nữa; và thiết kế privacy mechanisms mạnh hơn (Differential Privacy) phù hợp cho collaborative filtering.



THANK YOU

Thank you for your attention

